

机器学习复习

2022年4月25日 星期一

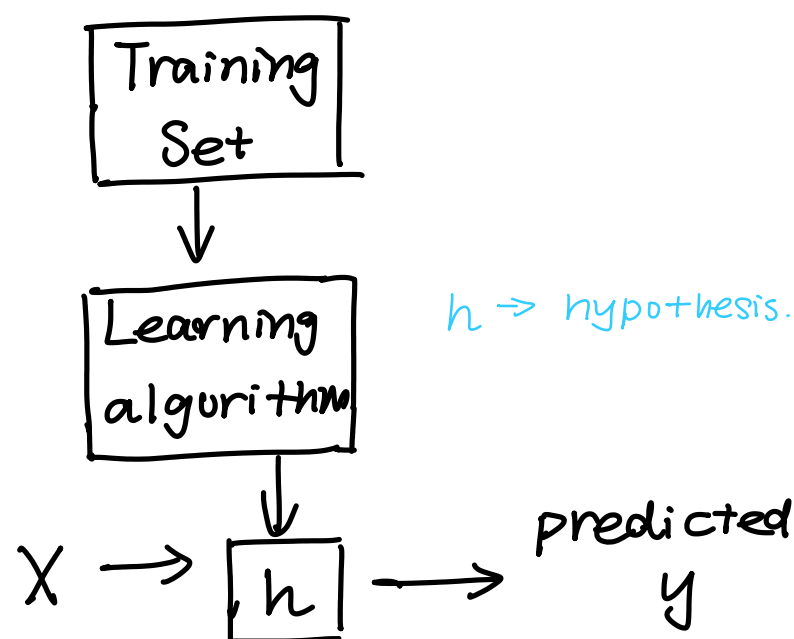
CS 229

2.1. 监督学习, 线性回归

① 预测房价模型 (提出训练集 n 个预测模型)

| Living Area (feet) ² | Price (1000 \$) |
|------------------------------------|--------------------|
| 2104 | 460 |
| 1600 | 330 |
| 2400 | 369 |
| ⋮ | ⋮ |

Put on a plot &
How to predict?



P1. Line

估计函数: $h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2$
 $h_{\theta}(x) = \theta^T x$

错误评价函数: $J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$
 $\min_{\theta} J(\theta)$

How to regulate θ . then get the min of $J(\theta)$?

• 梯度下降法 \rightarrow gradient descent // 利用 $h(\theta)$, 确定 α .

$$\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)} \quad \text{迭代找 } \theta_j$$

批梯度下降: 对全部 Data Set 求误差再更新 θ
增量梯度下降: 每扫描一步对 θ 更新.

• 最小二乘法 \rightarrow regulate function. // 找到一条直线, 使样本点离其距离和取 min.

$$\theta = (X^T X)^{-1} X^T \vec{y}$$

(X 需要满秩) (shortage: it's slow to reverse a matrix)

• 选用误差函数为平方和的概率解释. // 误差确定 equation

$$y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}$$

$$P(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \quad \text{// 误差满足正态分布, } \mu=0$$

$$\text{最大似然估计为: } J(\theta) = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left(-\frac{\sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

$$\Rightarrow \text{求导结果: } \frac{1}{\sigma^2} \sum_{i=1}^n (y^{(i)} - \theta^T x^{(i)}) x_j^{(i)}$$

• 带权重的线性回归

// 权重

Basic hypothesis: 1. Fit θ to minimize $\sum_i w^{(i)} (y^{(i)} - \theta^T x^{(i)})^2$
2. Output $\theta^T x$

$$w^{(i)} \text{ predict equation: } w^{(i)} = \exp\left(-\frac{(x^{(i)} - x)^2}{2\tau^2}\right)$$

其中 x 为预测特征, 离 x 越近, 权重越大

• 分类与对数回归

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}, \quad g(z) = \frac{1}{1 + e^{-z}}$$

$$\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$$

// 与线性回归类似, 将 $\theta^T x^{(i)}$ 换成了 $h_{\theta}(x^{(i)})$.

$h_{\theta}(x^{(i)})$ 由 $\theta^T x^{(i)}$ 经 $g(z)$ 映射而形成的

• 牛顿法解最大似然估计 // 解 $f(\theta) = 0$ 的方程.

$$\text{要求解 } f(\theta) = 0 \text{ 时, } \theta := \theta - \frac{f(\theta)}{f'(\theta)}$$

$$\text{2. 用于解最大似然估计时, } \theta := \theta - \frac{L'(\theta)}{L''(\theta)}$$

3. θ 为向量时, 牛顿法可以使用下式:

$$\theta := \theta - H^{-1} \nabla_{\theta} L(\theta), \quad \text{其中 } H_{ij} = \frac{\partial^2 L(\theta)}{\partial \theta_i \partial \theta_j} \text{ 是 } n \times n \text{ 的 Hessian 矩阵}$$

// 求 Hessian 矩阵比较耗时

当 x_0 靠近极小值 x^* 时, 牛顿法收敛速度最快, 但当 x_0 远离极小值时, 牛顿法可能不收敛, 甚至不能下降.

• 因为 $x_{k+1} - x^*$ 一定为 f 在牛顿方向上的极小点

• 一般线性模型. // 解释为什么用 $g(z) = \frac{1}{1 + e^{-z}}$ 作为二元机

一个概率分布: $P(y; \eta) = b(y) \exp(\eta^T T(y) - a(\eta))$

伯努利分布 (两点分布) 的概率表示为:

$$\begin{aligned} P(y; \phi) &= \phi^y (1 - \phi)^{1-y} \\ &= \exp(y \ln \phi + (1-y) \ln(1-\phi)) \\ &= \exp\left(y \ln \frac{\phi}{1-\phi} + \ln(1-\phi)\right) \end{aligned}$$

$$\text{令 } \eta = \ln \frac{\phi}{1-\phi} \quad \phi = \frac{1}{1 + e^{-\eta}}$$

$$(\eta = \theta^T x)$$

• Soft+max 回归.

预测值 y 有 K 种可能, $y \in \{1, 2, \dots, K\}$

Def: $\phi_i = P(y = i; \phi)$

$$\text{则 } \sum_{i=1}^K \phi_i = 1$$

$$P(y = K; \phi) = 1 - \sum_{i=1}^{K-1} \phi_i$$

取向量 $T(y)$ ($K-1$ dimension, use $T(y)$ to give $P(y=i)$)

$$T_{(1)} = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \quad T_{(2)} = \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix} \quad T_{(3)} = \begin{bmatrix} 0 \\ 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix} \quad \dots$$

$$T_{(K-1)} = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ 1 \end{bmatrix} \quad T_{(K)} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

适用于一般线性模型: $P(y; \phi) = \phi_1^{T_{(1)}} \phi_2^{T_{(2)}} \dots \phi_K^{1 - \sum_{i=1}^{K-1} T_{(i)}}$

$$= b(y) \exp(\eta^T T(y) - a(\eta))$$

$$\text{其中: } \eta = \begin{bmatrix} \log(\phi_1/\phi_K) \\ \log(\phi_2/\phi_K) \\ \vdots \\ \log(\phi_{K-1}/\phi_K) \end{bmatrix} \quad \begin{aligned} a(\eta) &= -\log(\phi_K) \\ b(y) &= 1 \end{aligned}$$

$$\phi_i = \frac{e^{\eta_i}}{\sum_{j=1}^K e^{\eta_j}}$$

最大似然估计: $L(\theta) = \sum_{i=1}^m \log(P(y^{(i)} | x^{(i)}; \theta))$

$$= \sum_{i=1}^m \log \prod_{k=1}^K \left(\frac{e^{\theta^T x^{(i)}}}{\sum_{j=1}^K e^{\theta^T x^{(i)}}} \right)^{1, y^{(i)}=k}$$

采用 GD 或牛顿迭代求解!